



CHAPITRE III: INDICATEURS STATISTIQUES

Méthodologie d'étude d'une série statistique:

- En pratique on est gêné en présence d'un grand nombre de données.
- Si l'intégralité de ces valeurs forme l'information complète, il n'est pas aisé de les manipuler ensemble.
- Il faut donc caractériser une variable statistique par un ensemble de paramètres.
- Les plus utilisées sont les caractéristiques : de position, de dispersion, de forme.

Introduction:

- La meilleure façon de résumer un ensemble de données par une seule valeur est de trouver la valeur la plus représentative, celle qui indique où se situe le **centre de la distribution**.
- C'est ce que l'on appelle **la tendance centrale**. Les trois mesures de tendance centrale les plus courantes sont :
 - Le mode
 - La moyenne arithmétique
 - La médiane.

II.1 Mode:

- Soit (x_j, n_j) une série statistique de caractère qualitatif ou quantitatif discret, associée à une population E d'effectif total n.
- **Le mode** est la valeur ou la modalité x_j du caractère qui a **le plus grand effectif**.

Exemple 1:

Les effectifs cumulés et les fréquences cumulées de la série des 'personnes à charge' sont :

| Valeurs x_j | Effectifs n_j | Fréquences f_j | Effectifs cumulés N_j | Fréquences cumulées F_j |
|------------------|--------------------|---------------------|----------------------------|------------------------------|
| 0 | 5 | 0.10 | 5 | 0.10 |
| 1 | 8 | 0.16 | 13 | 0.26 |
| 2 | 15 | 0.30 | 28 | 0.56 |
| 3 | 10 | 0.20 | 38 | 0.76 |
| 4 | 7 | 0.14 | 45 | 0.90 |
| 5 | 5 | 0.10 | 50 | 1 |
| Total | 50 | 1 | — | — |

Le mode de la série des 'Personnes à charge' est $x_3 = 2$ car $\max n_j = 15$.

Graphiquement, le mode 2 est la valeur de la variable associé au plus grand bâton dans le Diagramme en bâtons

II.1 Mode: (suite)**Exemple 2:**

Reprenons l'exemple de la série statistique des états civils pour des valeurs prises sur 20 personnes.

| x_j | n_j | f_j |
|----------|-------|-------|
| <i>C</i> | 9 | 0.45 |
| <i>M</i> | 7 | 0.35 |
| <i>V</i> | 2 | 0.10 |
| <i>D</i> | 2 | 0.10 |
| $n = 20$ | | 1 |

Le mode de cette série est $x_1 = C$ car $\max n_j = 9$.

II.2 Classe Modale:

- Soit (I_j, n_j) une série statistique de caractère quantitatif continu.
- **La classe modale** I_j est la classe qui a **le plus grand effectif corrigé**.

Exemple 3: La série des “Salaires horaires”

| Classes I_j | Effectifs n_j | Amplitudes a_j | Effectifs corrigés n'_j | Effectifs cumulés N_j |
|------------------|--------------------|---------------------|------------------------------|----------------------------|
| [47, 52[| 10 | 5 | 2 | 10 |
| [52, 57[| 30 | 5 | 6 | 40 |
| [57, 60[| 60 | 3 | 20 | 100 |
| [60, 63[| 72 | 3 | 24 | 172 |
| [63, 67[| 40 | 4 | 10 | 212 |
| [67, 77[| 38 | 10 | 3.8 | 250 |
| Total | 250 | 30 | — | — |

effectif corrigé: $h_j = n'_j = \frac{n_j}{a_j}$

La classe modale de la série des ‘Salaires Horaires est la classe $I_4 = [60, 63[$ car $\max n'_j = 24$

Graphiquement, la classe modale est la modalité associée au plus grand rectangle dans l’Histogramme des effectifs corrigés

II.2 Classe Modale: (suite)

Remarque:

- 1- Lorsque les classes sont de même amplitudes alors la classe modale est la classe qui a le plus grand effectif.
- 2- Le mode (ou classe modale) n'est pas nécessairement unique : 'Défaut' de cette caractéristique

II.3 Moyenne arithmétique

- C'est une valeur autour de la quelle se repartissent les observations.
- La moyenne peut être calculée pour les séries statistiques à caractère quantitatif
- Une série à caractère qualitatif ne possède pas de moyenne arithmétique.

a) Pour une série discrète (x_j, n_j) :

La moyenne arithmétique est: $\bar{X} = \frac{x_1n_1 + x_2n_2 + \dots + x_pn_p}{n}$ avec n : effectif total

La formule ci-dessus peut être écrite :

$$\bar{X} = \frac{1}{n} \sum_{i=1}^p x_i n_i$$

$$\text{ou } \bar{X} = \sum_{i=1}^p f_i x_i$$

II.3 Moyenne arithmétique (suite)**b) Pour une série continue (I_j, n_j):**

La moyenne arithmétique est définie de la même façon en retenant pour x_j les centres des classes I_j :

Exemple 3: La série des “Salaires horaires”

| Classes I_j | Effectifs n_j | Amplitudes a_j | Effectifs corrigés n_j^* | Effectifs cumulés N_j |
|------------------|--------------------|---------------------|-------------------------------|----------------------------|
| [47, 52[| 10 | 5 | 2 | 10 |
| [52, 57[| 30 | 5 | 6 | 40 |
| [57, 60[| 60 | 3 | 20 | 100 |
| [60, 63[| 72 | 3 | 24 | 172 |
| [63, 67[| 40 | 4 | 10 | 212 |
| [67, 77[| 38 | 10 | 3.8 | 250 |
| Total | 250 | 30 | — | — |

Les centres x_j :

$$x_1 = \frac{52 + 47}{2} = 49,5$$

$$x_2 = 54,5$$

$$x_3 = 58,5$$

$$x_4 = 61,5$$

$$x_5 = 65$$

$$x_6 = 73$$

$$\bar{X} = \frac{49,5 * 10 + 54,5 * 30 + 58,5 * 60 + 61,5 * 72 + 65 * 40 + 73 * 38}{250}$$

$$\bar{X} = 61,768$$

II.3 Moyenne arithmétique (suite)

Exemple 4 : *calculer la moyenne arithmétique de la série des personnes à charge*

Les effectifs cumulés et les fréquences cumulées de la série des 'personnes à charge' sont :

| Valeurs x_i | Effectifs n_i | Fréquences f_i | Effectifs cumulés N_i | Fréquences cumulées F_i |
|------------------|--------------------|---------------------|----------------------------|------------------------------|
| 0 | 5 | 0.10 | 5 | 0.10 |
| 1 | 8 | 0.16 | 13 | 0.26 |
| 2 | 15 | 0.30 | 28 | 0.56 |
| 3 | 10 | 0.20 | 38 | 0.76 |
| 4 | 7 | 0.14 | 45 | 0.90 |
| 5 | 5 | 0.10 | 50 | 1 |
| Total | 50 | 1 | — | — |

$$\bar{X} = \frac{0 * 5 + 1 * 8 + 2 * 15 + 3 * 10 + 4 * 7 + 5 * 5}{50}$$

$\bar{X} = 2,42$ Un salarié a en moyen environ 2.42 personnes à sa charge

II.3 Moyenne arithmétique (suite)

c) Propriétés de la moyenne arithmétique

□ *La moyenne arithmétique est associative*

- La moyenne globale d'une variable statistique sur l'agrégation de plusieurs populations est la moyenne pondérée des moyennes partielles.
- Soit P_a et P_b deux populations d'effectifs n_a et n_b , x une v. s. de moyennes arithmétiques \bar{X}_a et \bar{X}_b sur P_a et P_b respect.
- La moyenne arithmétique de x sur l'agrégation des deux populations $P = P_a \cup P_b$ est:

$$\bar{X} = \frac{n_a \bar{X}_a + n_b \bar{X}_B}{n_a + n_B}$$

L'intérêt pratique: La mise à jour facile de la moyenne dans le cas d'ajout d'une (des) observation(s)

II.3 Moyenne arithmétique (suite)

c) Propriétés de la moyenne arithmétique

□ *La moyenne arithmétique est associative*

Exemple 5

Le salaire moyen des 8 employés d'une entreprise est $\bar{X} = 26585$

Si l'entreprise recrute deux nouveaux employés qualifiés dont le revenu moyen est 100 000 Dh

Le nouveau revenu moyen des employés \bar{X}' est:

$$\bar{X}' = \frac{8 \times 26585 + 2 \times 100000}{8 + 2} = \boxed{41\ 268\ \text{Dh}}$$

II.3 Moyenne arithmétique (suite)

c) Propriétés de la moyenne arithmétique

□ *La moyenne arithmétique est sensible à la présence des valeurs aberrantes*

- Une valeur **aberrante** est une valeur qui n'est pas du même ordre de grandeur que la plus part des autres observations

Exemple:

Échantillon {1, 1, 2, 2, 2, 2, 3, 3} $\longrightarrow \bar{x} = 2$

Échantillon {1, 1, 2, 2, 2, 2, 3, 300} $\longrightarrow \bar{x} = 39.125.$

Cette propriété est en faite un 'défaut' de la moyenne arithmétique

II.4 Médiane:

a) Définition:

- La **médiane** est une valeur du caractère, notée $x_{1/2}$ (ou **Me**), partageant une série ordonnée en deux sous-ensembles à tailles égales (d'effectifs égaux.).
- La médiane peut être calculée pour les séries statistiques à **caractère quantitatif ou qualitatif ordinal**
- Une série à caractère qualitatif nominal ne possède pas de médiane.

II.4 Médiane:

b) Médiane d'une série discrète (x_j, n_j) et d'effectif total n :

- S'il existe une valeur x_j telle que son effectif cumulé $N_j = n/2$ alors: $x_{1/2} = \frac{x_{j-1} + x_j}{2}$
- Sinon, la valeur médiane est la plus petite valeur x_j dont l'effectif cumulé dépasse la moitié de l'effectif total:

$$x_{1/2} = x_j \Leftrightarrow N_{j-1} < \frac{n}{2} < N_j$$

On reprend l'exemple 4 : calculer la médiane de la série des personnes à charge

Les effectifs cumulés et les fréquences cumulées de la série des 'personnes à charge' sont :

| Valeurs x_i | Effectifs n_i | Fréquences f_i | Effectifs cumulés N_i | Fréquences cumulées F_i |
|------------------|--------------------|---------------------|----------------------------|------------------------------|
| 0 | 5 | 0.10 | 5 | 0.10 |
| 1 | 8 | 0.16 | 13 | 0.26 |
| 2 | 15 | 0.30 | 28 | 0.56 |
| 3 | 10 | 0.20 | 38 | 0.76 |
| 4 | 7 | 0.14 | 45 | 0.90 |
| 5 | 5 | 0.10 | 50 | 1 |
| Total | 50 | 1 | — | — |

$$n = 50$$

Le premier effectif cumulé qui dépasse $n/2 = 25$ est $N_2 = 28$

$$\Rightarrow x_{1/2} = x_3 = 2$$

Dans cet exemple, la médiane (2) est un peu plus petite que la moyenne (2,42).

II.4 Médiane:

Avantage:

- L'avantage d'utiliser la médiane plutôt que la moyenne est qu'elle est plus robuste aux valeurs extrêmes qui pourraient surgir à l'une des extrémités de la distribution.
- Il est donc important de vérifier si les données comptent des valeurs extrêmes avant de choisir quelle mesure de tendance centrale doit être utilisée.

Exercice 1:

Nous avons demandé aux 30 élèves d'une classe combien de personnes vivent dans leur ménage. Nous avons obtenu le tableau des effectifs suivant:

| Valeurs x_j | Effectifs n_j |
|------------------|--------------------|
| 2 | 3 |
| 3 | 4 |
| 4 | 10 |
| 5 | 4 |
| 6 | 2 |
| 7 | 3 |
| 8 | 1 |
| 9 | 2 |
| 10 | 1 |

- a) Compléter le tableau des effectifs (fréq, eff. Cum., fréq, cum.)
- b) Dessiner sa *Courbe cumulative*.
- c) Calculer la moyenne arithmétique
- d) Calculer la médiane
- e) Un nouvel élève est récemment inscrit en classe. Son ménage compte 18 résidents. Calculer la nouvelle moyenne et médiane.
- f) Laquelle des ces 2 caractéristiques est la plus robuste aux valeurs extrêmes?

II.4 Médiane:

c) Médiane d'une série continue:

- La détermination de la médiane $x_{1/2}$ se fait en 2 étapes:
 - 1) Détermination de la classe médiane $I_m = [x_m^-, x_m^+]$: c'est la 1^{ère} classe dont l'effectif cumulé dépasse $n/2$
 - 2) Détermination de la valeur médiane par une **interpolation linéaire** suivant la formule suivante:

$$x_{1/2} = x_m^- + (x_m^+ - x_m^-) \times \frac{n/2 - N_{m-1}}{N_m - N_{m-1}}$$

- **Exemple 3:** Considérons par exemple la distribution des salaires observés en continu:

| Salaires | Effectifs n_i | Effectifs cumulés N_i |
|--------------|-----------------|-------------------------|
| [1000, 2000[| 20 | 20 |
| [2000, 4000[| 50 | 70 |
| [4000, 6000[| 30 | 100 |
| Total | 100 | — |

la classe médiane est $I_2 = [2000, 4000[$ ayant $N_2 = 70 > 50$

$$\Rightarrow x_{1/2} \in I_m = I_2$$

la médiane de la série des salaires est: $x_{1/2} = 2000 + (4000 - 2000) \times \frac{50 - 20}{70 - 20} = \boxed{3\ 200\ \text{Dh}}$

II.4 Médiane:

c) Médiane d'une série continue: (suite)

- La détermination de la médiane $x_{1/2}$ peut se faire graphiquement:
 - 1) On trace la courbe cumulative $N(x)$ (une fonction linéaire par morceaux)
 - 2) On localise sur l'axe des abscisses la valeur correspondante à la valeur $n/2$ sur l'axe des ordonnées ; cette valeur est la médiane


Courbe cumulative:

On interpole les effectifs cumulés par une ligne brisée joignant les points d'abscisses (x_j^+, N_j)

II- Caractéristiques de position

- **Exemple 3:** Considérons par exemple la distribution des salaires observés en continu:

| Salaires | Effectifs n_i | Effectifs cumulés N_i |
|--------------|-----------------|-------------------------|
| [1000, 2000[| 20 | 20 |
| [2000, 4000[| 50 | 70 |
| [4000, 6000[| 30 | 100 |
| Total | 100 | — |



II.5 Quantiles:

- On généralise l'idée de médiane, en utilisant la notion de quantile où l'on va partager la distribution en plusieurs sous distributions de même taille.
- On appelle **quantile d'ordre α** (où $0 < \alpha < 1$) la valeur x_α de la variable telle que au moins $(\alpha * 100) \%$ des observations sont inférieures ou égales à x_α .
- La médiane est un quantile particulier d'ordre $\alpha = 0.5$

a) Quartiles:

- Pour une série statistique dont les valeurs sont classées par ordre croissant, la médiane partage la série en deux parties de même effectif.
- On peut aussi partager en **4 parties de même effectif**. On obtient ainsi trois valeurs **Q_1, Q_2, Q_3 appelés quartiles**.

b) Déciles:

- Lorsque l'étude porte sur une population très importante, on utilise souvent **les déciles** qui partagent la population en **10 parties de même effectif**.

II.5 Quantiles: (suite)

- Résumons les quantiles usuels :

| Quantiles | Ordres α | Notations | Sous-groupes |
|-----------|-------------------------|------------------------|------------------|
| Médiane | 0.5 | Me | $2 \times 50\%$ |
| Quartiles | (0.25, 0.50, 0.75) | (Q_1, Q_2, Q_3) | $4 \times 25\%$ |
| Deciles | (0.10, 0.20, ..., 0.90) | (D_1, \dots, D_9) | $10 \times 10\%$ |
| Centiles | (0.01, 0.02, ..., 0.99) | (C_1, \dots, C_{99}) | $100 \times 1\%$ |

Remarques:

- *Le premier quartile Q_1 est la plus petite valeur de la série telle que 25% des valeurs de la série lui soient inférieures ou égales.*
- *Le deuxième quartile Q_2 est la médiane*
- *Le troisième quartile Q_3 est la plus petite valeur de la série telle que 75% des valeurs de la série lui soient inférieures ou égales.*

II.5 Quantiles: (suite)

Exemple 6: Observons la série statistique des lancers de javelot suivante :

| | | | | | | | | |
|------------------|----|----|----|----|----|----|----|----|
| Longueur (en m) | 37 | 39 | 40 | 41 | 42 | 43 | 44 | 48 |
| Effectif | 4 | 3 | 4 | 2 | 2 | 4 | 5 | 2 |
| Effectif cumulés | 4 | 7 | 11 | 13 | 15 | 19 | 24 | 26 |

- *Le premier quartile Q_1 :* Le premier effectif cumulé qui dépasse $n/4 = 26/4 = 6,5$ est $N_2 = 7$

$$Q_1 = 39m$$

- *Le 2^{ème} quartile Q_2 ou La médiane:* $Me = 40, 5m$.

- *Le 3^{ème} quartile Q_3* Le premier effectif cumulé qui dépasse $3*n/4 = 3*6,5 = 19,5$ est $N_7 = 24$

$$Q_3 = 44m$$

Enfin, l'intervalle $[Q_1; Q_3] = [39; 44]$ contient 50% de la population.

II.5 Quantiles: (suite)

c) Cas d'une série continue

La détermination du quantile x_α est identique à celle de la médiane :

- ① Détermination de la classe $I_m := [x_m^-, x_m^+]$ qui inclue le quantile:
c'est la première classe dont l'effectif cumulé dépasse $\alpha * n$
- ② Détermination du quantile d'ordre α par l'interpolation linéaire :

$$x_\alpha = x_m^- + (x_m^+ - x_m^-) \times \frac{\alpha n - N_{m-1}}{N_m - N_{m-1}}.$$

II.5 Quantiles: (suite)**c) Cas d'une série continue**

$$x_{\alpha} = x_{\overline{m}} + (x_m^+ - x_{\overline{m}}) \times \frac{\alpha n - N_{m-1}}{N_m - N_{m-1}}.$$

- **Exemple 3:** Considérons par exemple la distribution des salaires observés en continu:

| Salaires | Effectifs n_i | Effectifs cumulés N_i |
|--------------|-----------------|-------------------------|
| [1000, 2000[| 20 | 20 |
| [2000, 4000[| 50 | 70 |
| [4000, 6000[| 30 | 100 |
| Total | 100 | — |

Déterminons les **quartiles** Q_1, Q_2, Q_3

- Premier quartile $Q_1 = x_{1/4}$: Le premier effectif cumulé qui dépasse $n/4 = 100/4 = 25$ est $N_2 = 70$

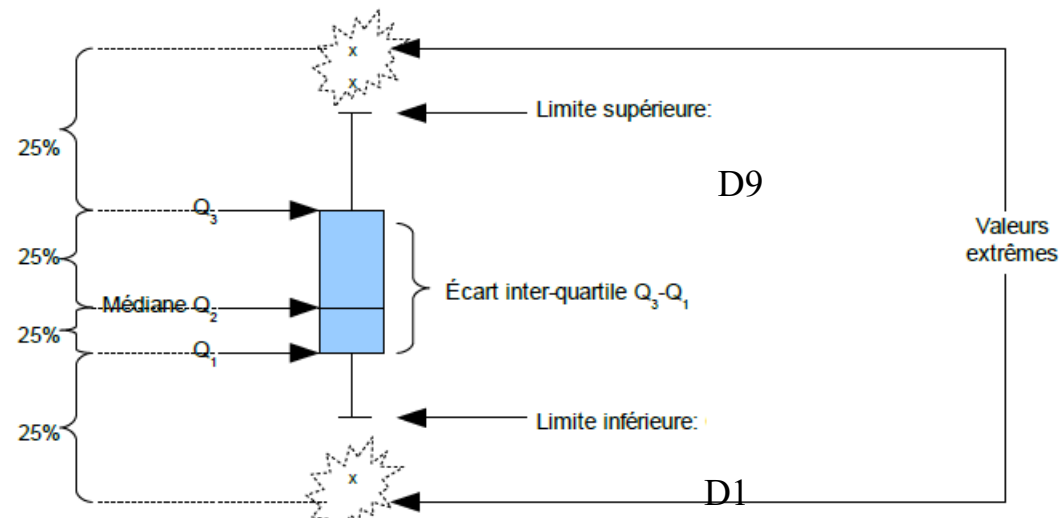
Alors $Q_1 \in I_2 = [2000, 4000[$ $Q_1 = 2000 + (4000 - 2000) \times \frac{25 - 20}{70 - 20} = \boxed{2\,200}.$

- troisième quartile $Q_3 = x_{3/4}$: Le premier effectif cumulé qui dépasse $3 \cdot n/4 = 75$ est $N_3 = 100$

Alors $Q_3 \in I_3 = [4000, 6000[$ $Q_3 = 4000 + (6000 - 4000) \times \frac{75 - 70}{100 - 70} \approx \boxed{4\,333.33}.$

II.6 Diagramme de Tukey

- Un **diagramme de Tukey** (aussi appelé « **boîte à moustache** ») est un résumé, sur un axe gradué, des quantiles.
- Ce diagramme est constitué:
 - 1- d'une boîte (dont la hauteur est prise de manière arbitraire) délimitée par le 1^{er} et 3^{ème} quartiles (Q_1 et Q_3).
 - 2- Cette même boîte est ensuite partagée par la médiane.
 - 3- Deux segments « moustaches » sortent des deux côtés du rectangle et sont délimitées par les valeurs D_1 et D_9



II.7 Conclusion

Le tableau ci-dessous résume les paramètres de position envisageable en fonction du type de la variable étudiée :

| | Quantitative | Ordinale | Nominale |
|------------------|--------------|----------|----------|
| Moyenne | OUI | NON | NON |
| Médiane | OUI | OUI | NON |
| Quantiles | OUI | OUI | NON |
| Modes | OUI | OUI | OUI |